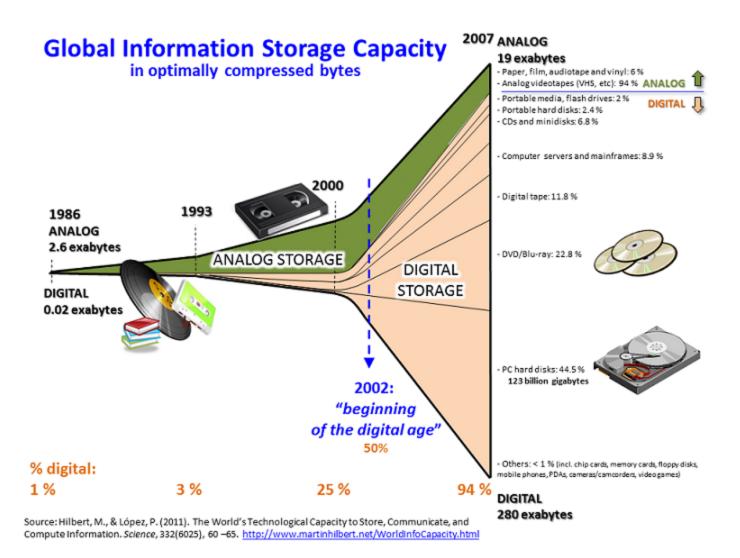
# Introduction à la Big Data



#### Concept et historique

par Fabien Barbaud - @BarbaudFabien

# Augmentation des capacités de stockage



• Volume:

téra  $(10^{12})$ , péta  $(10^{15})$ , exa  $(10^{18})$ , zetta  $(10^{21})$ , yotta  $(10^{24})$ 

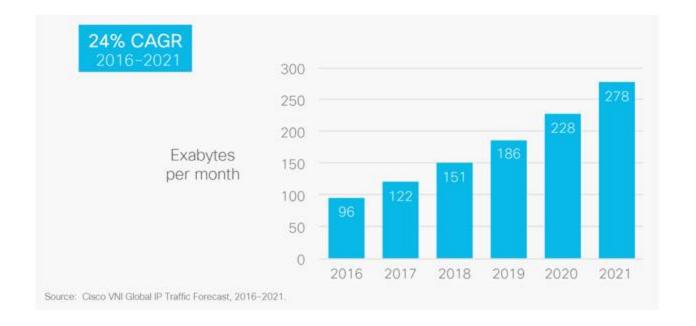
• Variété:

Profil, activité, interaction, statistique, image, voix, ...

• Vélocité:

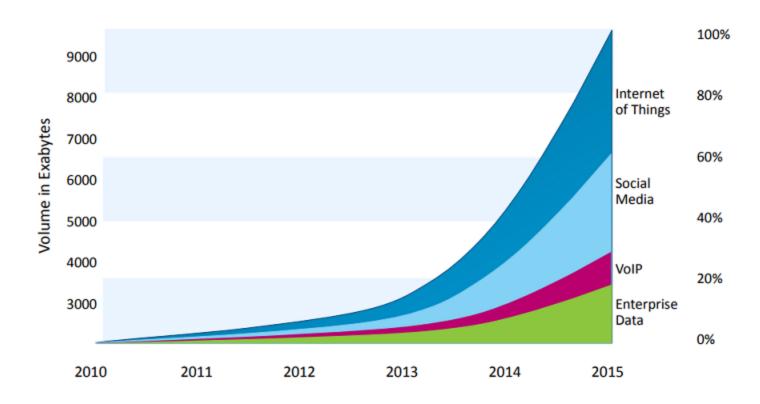
Temps réel, milliseconde, haute fréquence, ...

#### Volume



The Zettabyte Era: Trends and Analysis

#### Volume



Source: IBM Global Technology Outlook

Be a Smarter Business by Unlocking your Internet of Things

### Variété

**Produit** 

```
{
   "_id": {
        "$oid": "5968dd23fc13ae04d9000001"
   },
   "product_name": "sildenafil citrate",
   "supplier": "Wisozk Inc",
   "quantity": 261,
   "unit_cost": "$10.47"
}
```

#### 10 Example JSON Files

#### Variété

GeoIP

```
"as": "AS16509 Amazon.com, Inc.",
"city": "Boardman",
"country": "United States",
"countryCode": "US",
"isp": "Amazon",
"lat": 45.8696,
"lon": -119.688,
"regionName": "Oregon",
"status": "success",
"timezone": "America\/Los_Angeles",
"zip": "97818"
```

7

#### Variété

**Twitter** 

```
"created_at": "Thu Jun 22 21:00:00 +0000 2017",
"id": 877994604561387500,
"id_str": "877994604561387520",
"text": "....",
"entities": {
  "hashtags": [{
  }],
  "user_mentions": [],
  "urls": [{
    "url": "https://t.co/xFox78juL1",
 }]
```

#### Variété

WordPress

```
"id": 157538,
"date": "2017-07-21T10:30:34",
"date gmt": "2017-07-21T17:30:34",
"guid": {
   "rendered": "https://www.sitepoint.com/?p=157538"
"modified": "2017-07-23T21:56:35",
"modified gmt": "2017-07-24T04:56:35",
"slug": "why-the-iot-threatens-your-wordp..",
"status": "publish",
"type": "post",
"link": "https://www.sitepoint.com/why-the-io...",
```

#### Vélocité



### Et les autres

- Variabilité
- Véracité
- Visualisation
- Valeur

### La démocratisation de la "Big Data"



- 2004
- Doug Cutting
- Framework
- Java
- Doudou

#### En résumé

Hadoop est un framework libre et open source écrit en Java destiné à faciliter la création d'applications distribuées (au niveau du stockage des données et de leur traitement) et échelonnables (scalables) permettant aux applications de travailler avec des milliers de nœuds et des pétaoctets de données.

[...] *Hadoop* a été inspiré par la publication de *MapReduce*, *GoogleFS* et *BigTable* de Google

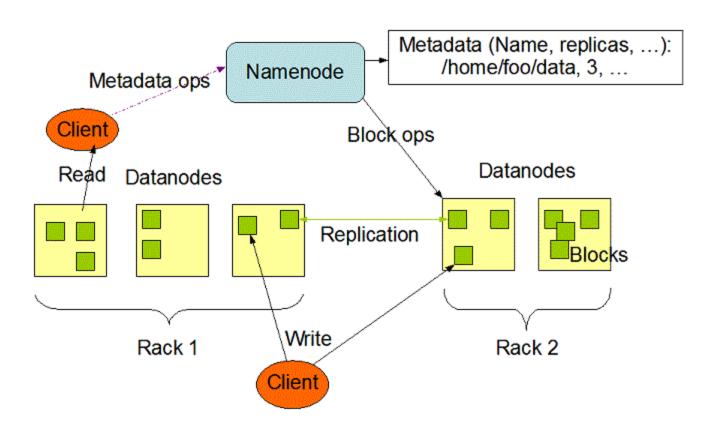
Wikipedia

#### L'architecture

- Hadoop Distributed File System (HDFS)
- YARN
- MapReduce

#### **HDFS**

#### **HDFS Architecture**



#### **HDFS**

- *NameNode* : gestion de l'espace de noms, de l'arborescence et des métadonnées
- DataNode: stockage des blocs de données

### **HDFS** - Quelques commandes

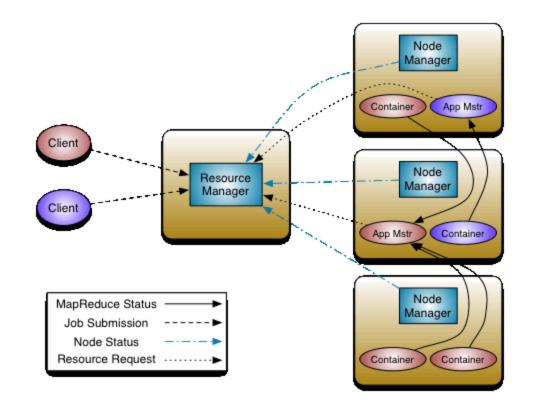
```
hadoop fs -mkdir
hadoop fs -ls
hadoop fs -put
hadoop fs -get
hadoop fs -cp
hadoop fs -mv
...
```

### **HDFS** - Exercice pratique

```
$ docker pull sequenceiq/hadoop-docker:2.7.1
$ docker run -it sequenceiq/hadoop-docker:2.7.1 \
    /etc/bootstrap.sh -bash
bash-4.1# cd $HADOOP_PREFIX
bash-4.1# bin/hadoop version
bash-4.1# bin/hadoop fs -mkdir test
bash-4.1# bin/hadoop fs -ls
bash-4.1# bin/hadoop fs
```

https://github.com/sequenceiq/hadoop-docker

#### **YARN**



### Apache Hadoop YARN

#### **YARN**

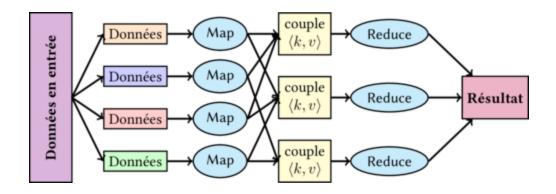
- Resource Manager: arbitre la gestion des ressources au sein du cluster
- Node Manager: fournit les ressources du nœud sous forme de Container
- Application Master : coordonne l'exécution des tâches
- Container : exécute les tâches

#### YARN - Web UI

```
$ docker run -p 8088:8088 -it sequenceiq/hadoop-docker:2.7.1 \
  /etc/bootstrap.sh -bash
```

http://localhost:8088

### MapReduce



#### Wikipedia

input (k1, v1)
-> map -> (k2, v2)
-> combine -> (k2, v2)
-> reduce -> (k3, v3)
output

22

### Par l'exemple : WordCount

Input (flux d'entrée):

```
Conseil tenu par les rats

Un chat, nommé Rodilardus,
Faisait des rats telle déconfiture

Que l'on n'en voyait presque plus,
Tant il en avait mis dedans la sépulture.

Le peu qu'il en restait n'osant quitter son trou
...
```

### Par l'exemple : WordCount

Mapper:

```
import sys

for line in sys.stdin:
    line = line.strip()
    keys = line.split()
    for key in keys:
       value = 1
       print('%s\t%d' % (key, value))
```

24

Par l'exemple : WordCount

Reducer:

```
import sys
last key = None
running_total = 0
for input_line in sys.stdin:
    input line = input line.strip()
   this_key, value = input_line.split("\t", 1)
   value = int(value)
    if last key == this key:
        running total += value
    else:
        if last key:
            print("%s\t%d" % (last_key, running_total))
        running_total = value
        last key = this key
if last key == this key:
    print("%s\t%d" % (last_key, running_total))
```

26

### Par l'exemple : WordCount

```
bash-4.1# bin/hadoop fs -cat wordcount/output/*
```

#### **Exercice**

- Récupérez une source de données sur data.gouv.fr
- Importez ces données en HDFS
- Développez un code MapReduce en Python pour en extraire une nouvelle information
- Représentez-là sous forme de graphique

# Base de données et Big Data

### Les principes fondamentaux

- *Partitioning* : basé sur les colonnes
- Sharding: basé sur les clés d'une ligne

# Base de données et Big Data

### **Partitioning**

Col1	Col2	Col3	Col4	Col5	Col6
_					

\_\_\_

Col1	Col2	Col3	Col4
_			

Col5	Col6
_	

# Base de données et Big Data

### **Sharding - Horizontal partitioning**

Key	Col1	Col2	Col3
X			
У			
Z			

Key	Col1	Col2	Col3
X			

Key	Col1	Col2	Col3
У			
Z uction à la	a Big Data		



- Base de données orientée colonnes
- Installé sur le système de fichier HDFS

### Système de stockage

rowkey1	column family (CF11)					column family (CF12)				
	column111		colum	nn112	column113		column121		column122	
	version1111 value1111		version1121	value1121	version1121	value1131	version1211	value1211	version1221	value1221
	version1112	value1112	version1122	value1122					version1222	value1222
			version1123	value1123						
			version1124	value1124						

**HBase Schema** 

### Système de stockage

- Une table est une collection de rows
- Une *row* est une collection de *columns family*
- Une column family est une collection de columns
- Une *column* est une collection de clé/valeur

### Système de stockage

#### **HBase Shell**

```
$ docker pull dajobe/hbase
$ mkdir data
$ docker run --name=hbase-docker -h hbase-docker -d \
-v $PWD/data:/data dajobe/hbase
$ docker exec -it hbase-docker bash
root@hbase-docker:/# hbase shell
```

#### **HBase Shell**

#### **HBase Tutorial**

```
> status
1 active master, 0 backup masters, 1 servers, 1 dead, 2.0000 av

> list
TABLE
0 row(s) in 0.0820 seconds
=> []
```

### HBase Shell - Création d'une table

```
> create 'emp', 'personal data', 'professional data'
0 row(s) in 1.3160 seconds
=> Hbase::Table - emp
```

```
> list
TABLE
emp
1 row(s) in 0.0440 seconds
=> ["emp"]
```

38

### **HBase Shell - Désactivation**

```
> disable 'emp'
0 row(s) in 2.3980 seconds
```

```
> is_disabled 'emp'
true
0 row(s) in 0.0110 seconds
```

### **HBase Shell - Activation**

0 row(s) in 0.0280 seconds

```
> enable 'emp'
0 row(s) in 1.3110 seconds
> is_enabled 'emp'
true
```

#### **HBase Shell - Ecriture**

```
> put 'emp','1','personal data:name','raju'
> put 'emp','1','personal data:city','hyderabad'
> put 'emp','1','professional data:designation','manager'
> put 'emp','1','professional data:salary','50000'
```

```
> scan 'emp'
```

## HBase Shell - Mise à jour

```
> put 'emp','1','personal data:city','Delhi'
ROW COLUMN+CELL
1    column=personal data:city, timestamp=1503511522300, value=
1    column=personal data:name, timestamp=1503511282272, value=
1    column=professional data:designation, timestamp=1503511332
1    column=professional data:salary, timestamp=1503511341265,
1    row(s) in 0.0250 seconds
```

#### HBase Shell - Accès

### HBase Shell - Accès à une colonne

## **HBase Shell - Suppression**

```
> delete 'emp', '1', 'personal data:city'
> deleteall 'emp','1'
> scan 'emp'
```

45

### HBase Shell - Sécurité

- R lecture
- W écriture
- X exécution
- C création
- A admin

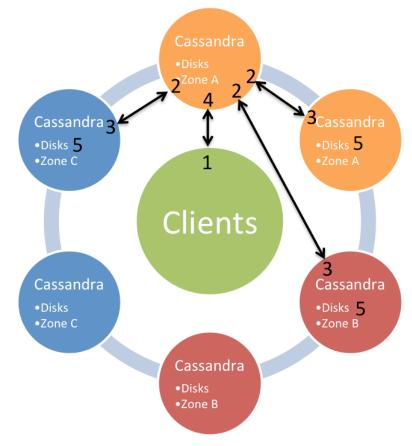
```
> grant 'bobsmith', 'RWXCA'
> revoke 'bobsmith'
```



- Tolérance à la panne
- Décentralisé
- Scalable

# Cassandra Write Data Flows Single Region, Multiple Availability Zone

- Client Writes to any Cassandra Node
- Coordinator Node replicates to nodes and Zones
- Nodes return ack to coordinator
- 4. Coordinator returns ack to client
- Data written to internal commit log disk



If a node goes offline, hinted handoff completes the write when the node comes back up.

Requests can choose to wait for one node, a quorum, or all nodes to ack the write

SSTable disk writes and compactions occur asynchronously



### **Tutorial**

```
$ docker pull cassandra
$ docker run --name=cassandra -d library/cassandra
$ docker exec -it cassandra bash
root@a6b74edad198:/#
```

Cassandra Tutorial

## cqlsh

```
root@dce317a979a6:/# cqlsh
Connected to Test Cluster at 127.0.0.1:9042.
[cqlsh 5.0.1 | Cassandra 3.11.4 | CQL spec 3.4.4 | Native proto
Use HELP for help.
cqlsh>
```

Cassandra Query Language (CQL)

## Keyspace

```
cqlsh> CREATE KEYSPACE tutorialspoint
WITH replication = {'class':'SimpleStrategy',
'replication_factor' : 3};
cqlsh> DESCRIBE keyspaces;
```

### **Table**

```
cqlsh> USE tutorialspoint;
cqlsh:tutorialspoint> CREATE TABLE emp(
   emp_id int PRIMARY KEY,
   emp_name text,
   emp_city text,
   emp_sal varint,
   emp_phone varint
   );
cqlsh:tutorialspoint> select * from emp;
```

#### Créer

```
cqlsh:tutorialspoint> INSERT INTO emp
(emp_id, emp_name, emp_city, emp_phone, emp_sal)
VALUES (1,'ram', 'Hyderabad', 9848022338, 50000);
cqlsh:tutorialspoint> INSERT INTO emp
(emp_id, emp_name, emp_city, emp_phone, emp_sal)
VALUES (2,'robin', 'Hyderabad', 9848022339, 40000);
cqlsh:tutorialspoint> INSERT INTO emp
(emp_id, emp_name, emp_city, emp_phone, emp_sal)
VALUES (3,'rahman', 'Chennai', 9848022330, 45000);
cqlsh:tutorialspoint> SELECT * FROM emp;
```

## Mettre à jour

```
cqlsh:tutorialspoint> UPDATE emp
SET emp_city='Delhi',emp_sal=50000
WHERE emp_id=2;
cqlsh:tutorialspoint> SELECT * FROM emp;
```

### Lire

```
cqlsh:tutorialspoint> SELECT emp_name, emp_sal from emp;
cqlsh:tutorialspoint> SELECT * FROM emp WHERE emp_sal=50000;
cqlsh:tutorialspoint> CREATE INDEX ON emp(emp_sal);
cqlsh:tutorialspoint> SELECT * FROM emp WHERE emp_sal=50000;
```

55

## Supprimer

```
cqlsh:tutorialspoint> DELETE emp_sal FROM emp WHERE emp_id=3;
cqlsh:tutorialspoint> SELECT * FROM emp;
cqlsh:tutorialspoint> DELETE FROM emp WHERE emp_id=3;
cqlsh:tutorialspoint> SELECT * FROM emp;
```

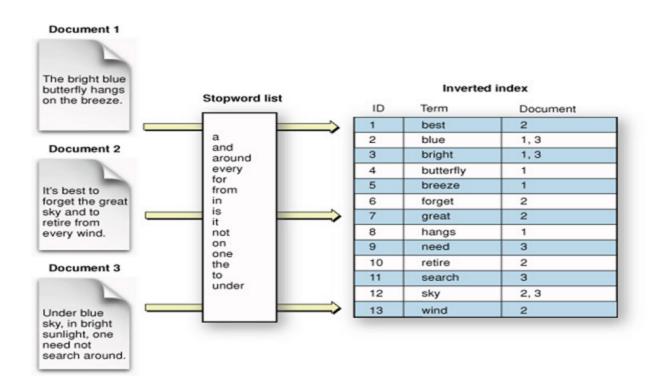
56

## Elasticsearch



- Indexation et recherche de données
- Moteur Lucene
- API HTTP RESTful en JSON

## Elasticsearch



Elasticsearch Tutorial - Elasticsearch Storage Architecture : Analysis and Inverted Indexes

## Elasticsearch

### **Tutorial**

```
$ docker pull docker.elastic.co/elasticsearch/elasticsearch:7.2
$ docker run --name=elasticsearch -d -p 9200:9200 \
-e "http.host=0.0.0.0" -e "transport.host=127.0.0.1" \
docker.elastic.co/elasticsearch/elasticsearch:7.2.1
$ curl -u elastic http://127.0.0.1:9200/
```

Utilisateur: elastic

Mot de passe : changeme

**Elasticsearch Tutorial**