Introduction à la Big Data

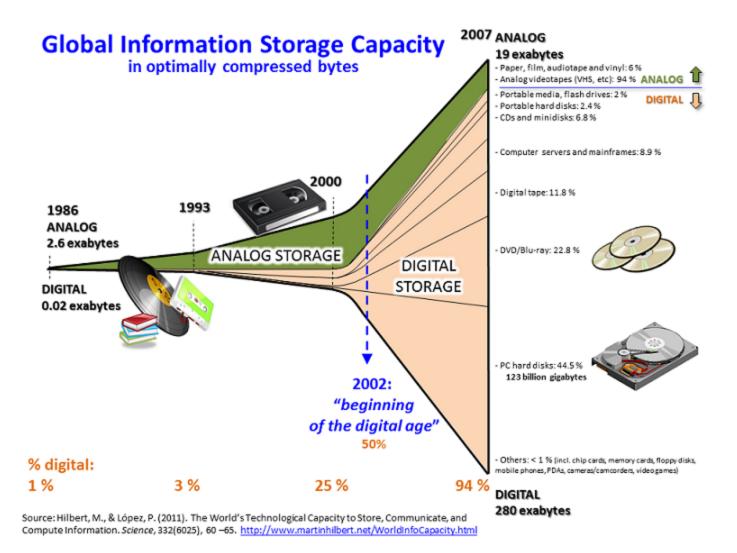


Concept et historique

ntroduction à la Big Data

Barbaud - @BarbaudFabien

Augmentation des capacités de stockage



• Volume:

téra (10^{12}) , péta (10^{15}) , exa (10^{18}) , zetta (10^{21}) , yotta (10^{24})

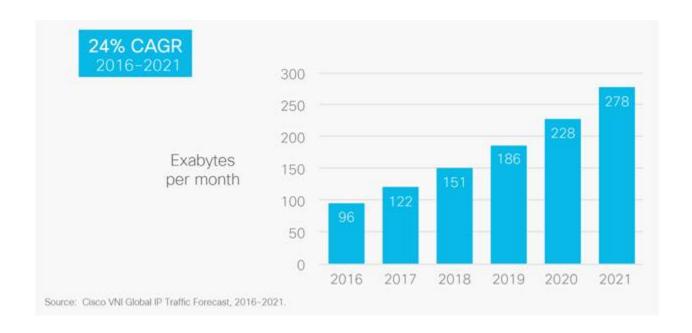
• Variété :

Profil, activité, interaction, statistique, image, voix, ...

Vélocité :

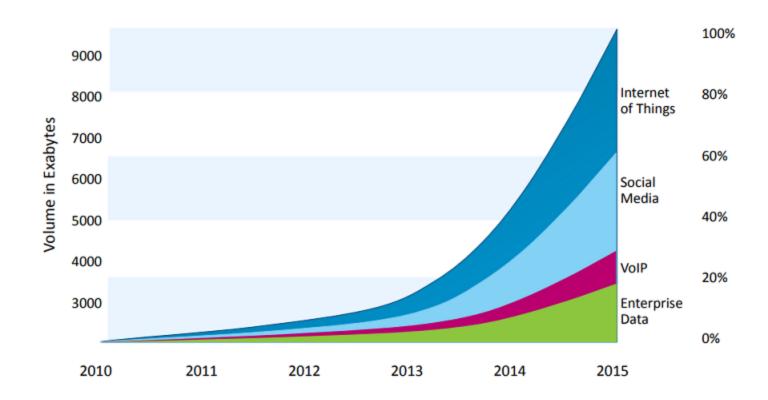
Temps réel, milliseconde, haute fréquence, ...

Volume



The Zettabyte Era: Trends and Analysis

Volume



Source: IBM Global Technology Outlook

Variété

Produit

```
{
   "_id": {
        "$oid": "5968dd23fc13ae04d9000001"
   },
   "product_name": "sildenafil citrate",
   "supplier": "Wisozk Inc",
   "quantity": 261,
   "unit_cost": "$10.47"
}
```

10 Example JSON Files

Variété

GeoIP

```
"as": "AS16509 Amazon.com, Inc.",
      "city": "Boardman",
      "country": "United States",
      "countryCode": "US",
      "isp": "Amazon",
      "lat": 45.8696,
      "lon": -119.688,
      "regionName": "Oregon",
      "status": "success",
      "timezone": "America\/Los_Angeles",
      "zip": "97818"
Introduction à la Big Data
```

Variété

Twitter

```
"created_at": "Thu Jun 22 21:00:00 +0000 2017",
"id": 877994604561387500,
"id_str": "877994604561387520",
"text": "....",
"entities": {
  "hashtags": [{
  "user_mentions": [],
  "urls": [{
    "url": "https://t.co/xFox78juL1",
  }]
```

Variété

WordPress

```
"id": 157538,
"date": "2017-07-21T10:30:34",
"date_gmt": "2017-07-21T17:30:34",
"guid": {
   "rendered": "https://www.sitepoint.com/?p=157538"
"modified": "2017-07-23T21:56:35",
"modified_gmt": "2017-07-24T04:56:35",
"slug": "why-the-iot-threatens-your-wordp..",
"status": "publish",
"type": "post",
"link": "https://www.sitepoint.com/why-the-io...",
```

Introduction à la Big Data

Vélocité



Et les autres

- Variabilité
- Véracité
- Visualisation
- Valeur

La démocratisation de la "Big Data"



- 2004
- Doug Cutting
- Framework
- Java
- Doudou

En résumé

Hadoop est un *framework* libre et *open source* écrit en Java destiné à faciliter la création d'applications distribuées (au niveau du stockage des données et de leur traitement) et échelonnables (scalables) permettant aux applications de travailler avec des milliers de nœuds et des pétaoctets de données.

[...] *Hadoop* a été inspiré par la publication de *MapReduce*, *GoogleFS* et *BigTable* de Google

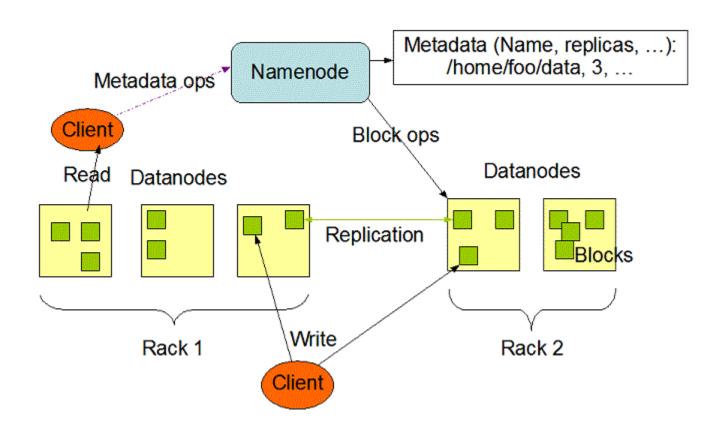
Wikipedia

L'architecture

- Hadoop Distributed File System (HDFS)
- YARN
- MapReduce

HDFS

HDFS Architecture



HDFS

- *NameNode :* gestion de l'espace de noms, de l'arborescence et des métadonnées
- DataNode : stockage des blocs de données

HDFS - Quelques commandes

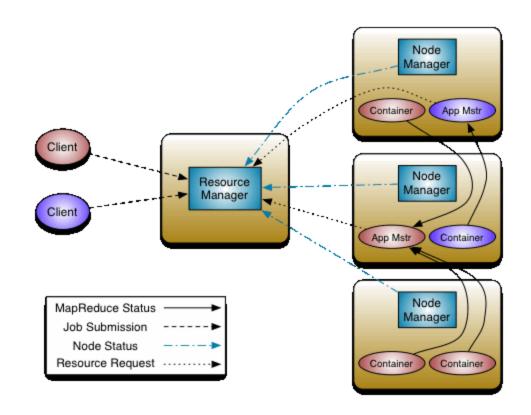
```
hadoop fs -mkdir
hadoop fs -ls
hadoop fs -put
hadoop fs -get
hadoop fs -cp
hadoop fs -mv
...
```

HDFS - Exercice pratique

```
$ git clone https://github.com/fabienbarbaud/docker-hadoop.git
$ cd docker-hadoop
$ docker-compose up -d
$ docker-compose run --rm client bash
root@0f0355fc41b0:/# hadoop version
root@0f0355fc41b0:/# hdfs dfs -mkdir /input
root@0f0355fc41b0:/# hdfs dfs -ls /
```

Fork https://github.com/big-data-europe/docker-hadoop

YARN

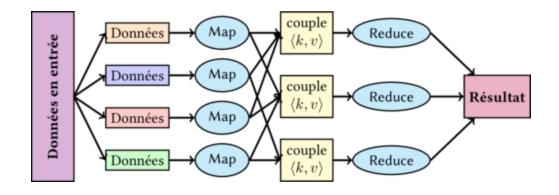


Apache Hadoop YARN Introduction à la Big Data

YARN

- Resource Manager: arbitre la gestion des ressources au sein du cluster
- Node Manager : fournit les ressources du nœud sous forme de Container
- Application Master : coordonne l'exécution des tâches
- Container : exécute les tâches

MapReduce



Wikipedia

input (k1, v1)

- -> map -> (k2, v2)
- -> combine -> (k2, v2)
- -> **reduce** -> (k3, v3)

Par l'exemple : WordCount

Input (flux d'entrée) :

```
Conseil tenu par les rats

Un chat, nommé Rodilardus,
Faisait des rats telle déconfiture
Que l'on n'en voyait presque plus,
Tant il en avait mis dedans la sépulture.
Le peu qu'il en restait n'osant quitter son trou
```

Par l'exemple : WordCount

Mapper:

```
import sys

for input_line in sys.stdin:
    input_line = input_line.strip()
    keys = input_line.split()
    for key in keys:
       value = 1
       print('%s\t%d' % (key, value))
```

Par l'exemple : WordCount

Reducer:

```
import sys
last_key = None
running_total = 0
for input_line in sys.stdin:
    input_line = input_line.strip()
    this_key, value = input_line.split("\t", 1)
    value = int(value)
    if last_key == this_key:
        running_total += value
    else:
        if last_key:
            print("%s\t%d" % (last_key, running_total))
        running_total = value
        last_key = this_key
if last_key == this_key:
    print("%s\t%d" % (last_key, running_total))
```

Par l'exemple : WordCount

```
root@0f0355fc41b0:/# cd /files/wordcount
root@0f0355fc41b0:/files/wordcount# cat conseil-tenu-par-les-rats.txt | ./mapper.py | sort | ./reducer.py
```

```
root@0f0355fc41b0:/files/wordcount# hdfs dfs -mkdir /wordcount
root@0f0355fc41b0:/files/wordcount# hdfs dfs -put conseil-tenu-par-les-rats.txt /wordcount/fable.txt
root@0f0355fc41b0:/files/wordcount# hadoop jar /opt/hadoop-3.2.1/share/hadoop/tools/lib/hadoop-streaming-3.2.1.jar \
    -mapper "mapper.py" \
    -reducer "reducer.py" \
    -file "mapper.py" \
    -input "/wordcount/fable.txt" \
    -output "/wordcount/output"
```

root@0f0355fc41b0:/files/wordcount# hdfs dfs -cat /wordcount/output/*

Exercice

- Récupérez une source de données sur data.gouv.fr
- Importez ces données en HDFS
- Développez un code *MapReduce* en Python pour en extraire une nouvelle information

Base de données et Big Data

Les principes fondamentaux

- *Partitioning* : basé sur les colonnes
- Sharding : basé sur les clés d'une ligne

Base de données et Big Data

Partitioning

Col1	Col2	Col3	Col4	Col5	Col6

Col1	Col2	Col3	Col4

Col5	Col6

Base de données et Big Data

Sharding - Horizontal partitioning

Key	Col1	Col2	Col3
X			
У			

Key	Col1	Col2	Col3

Key	Col1	Col2	Col3
У			



- Base de données orientée colonnes
- Installé sur le système de fichier HDFS

Système de stockage

rowkey1	column family (CF11)					column family (CF12)				
	column111		colum	nn112	column113		column121		column122	
	version1111	value1111	version1121	value1121	version1121	value1131	version1211	value1211	version1221	value1221
	version1112	value1112	version1122	value1122					version1222	value1222
			version1123	value1123						
			version1124	value1124						

HBase Schema

Système de stockage

- Une *table* est une collection de *rows*
- Une *row* est une collection de *columns family*
- Une column family est une collection de columns
- Une column est une collection de clé/valeur

Système de stockage

HBase Shell

```
$ docker pull dajobe/hbase
$ mkdir data
$ docker run --name=hbase-docker -h hbase-docker -d \
-v $PWD/data:/data dajobe/hbase
$ docker exec -it hbase-docker bash
root@hbase-docker:/# hbase shell
```

HBase Shell

HBase Tutorial

```
> status
1 active master, 0 backup masters, 1 servers, 1 dead, 2.0000 average load
```

```
> list
TABLE
0 row(s) in 0.0820 seconds
=> []
```

HBase Shell - Création d'une table

```
> create 'emp', 'personal data', 'professional data'
0 row(s) in 1.3160 seconds
=> Hbase::Table - emp
```

```
> list
TABLE
emp
1 row(s) in 0.0440 seconds
=> ["emp"]
```

HBase Shell - Désactivation

```
> disable 'emp'
0 row(s) in 2.3980 seconds
```

```
> is_disabled 'emp'
true
0 row(s) in 0.0110 seconds
```

HBase Shell - Activation

```
> enable 'emp'
0 row(s) in 1.3110 seconds
```

```
> is_enabled 'emp'
true
0 row(s) in 0.0280 seconds
```

HBase Shell - Ecriture

```
> put 'emp','1','personal data:name','raju'
> put 'emp','1','personal data:city','hyderabad'
> put 'emp','1','professional data:designation','manager'
> put 'emp','1','professional data:salary','50000'
```

```
> scan 'emp'
```

HBase Shell - Mise à jour

```
> put 'emp','1','personal data:city','Delhi'
ROW COLUMN+CELL
1 column=personal data:city, timestamp=1503511522300, value=Delhi
1 column=personal data:name, timestamp=1503511282272, value=raju
1 column=professional data:designation, timestamp=1503511332216, value=manager
1 column=professional data:salary, timestamp=1503511341265, value=50000
1 row(s) in 0.0250 seconds
```

HBase Shell - Accès

HBase Shell - Accès à une colonne

HBase Shell - Suppression

```
> delete 'emp', '1', 'personal data:city'
> deleteall 'emp','1'
> scan 'emp'
```

HBase Shell - Sécurité

- R lecture
- W écriture
- X exécution
- C création
- A admin
- > grant 'bobsmith', 'RWXCA'
- > revoke 'bobsmith'

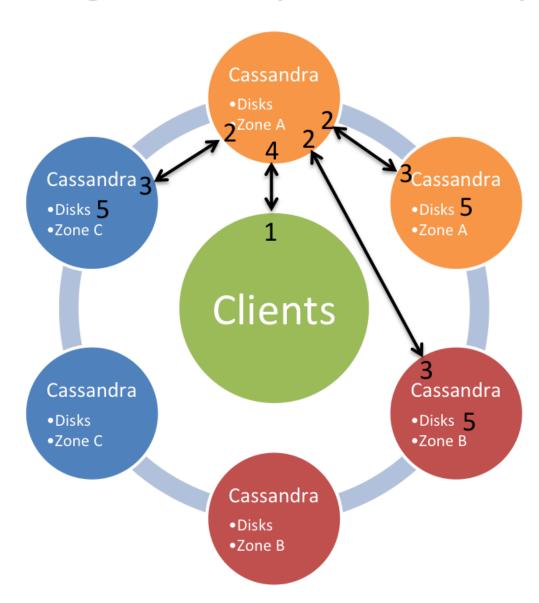


- Tolérance à la panne
- Décentralisé
- Scalable

dosaliala Wille Data i lows

Single Region, Multiple Availability Zone

- Client Writes to any Cassandra Node
- Coordinator Node replicates to nodes and Zones
- Nodes return ack to coordinator
- Coordinator returns ack to client
- Data written to internal commit log disk



If a node goes offline, hinted handoff completes the write when the node comes back up.

Requests can choose to wait for one node, a quorum, or all nodes to ack the write

SSTable disk writes and compactions occur asynchronously



Tutorial

```
$ docker pull cassandra
$ docker run --name=cassandra -d library/cassandra
$ docker exec -it cassandra bash
root@a6b74edad198:/#
```

Cassandra Tutorial

cqlsh

```
root@dce317a979a6:/# cqlsh
Connected to Test Cluster at 127.0.0.1:9042.
[cqlsh 5.0.1 | Cassandra 3.11.4 | CQL spec 3.4.4 | Native protocol v4]
Use HELP for help.
cqlsh>
```

Cassandra Query Language (CQL)

Keyspace

```
cqlsh> CREATE KEYSPACE tutorialspoint
WITH replication = {'class':'SimpleStrategy',
'replication_factor' : 3};
cqlsh> DESCRIBE keyspaces;
```

Table

```
cqlsh> USE tutorialspoint;
cqlsh:tutorialspoint> CREATE TABLE emp(
   emp_id int PRIMARY KEY,
   emp_name text,
   emp_city text,
   emp_sal varint,
   emp_phone varint
   );
cqlsh:tutorialspoint> select * from emp;
```

Créer

```
cqlsh:tutorialspoint> INSERT INTO emp
(emp_id, emp_name, emp_city, emp_phone, emp_sal)
VALUES (1,'ram', 'Hyderabad', 9848022338, 50000);
cqlsh:tutorialspoint> INSERT INTO emp
(emp_id, emp_name, emp_city, emp_phone, emp_sal)
VALUES (2,'robin', 'Hyderabad', 9848022339, 40000);
cqlsh:tutorialspoint> INSERT INTO emp
(emp_id, emp_name, emp_city, emp_phone, emp_sal)
VALUES (3,'rahman', 'Chennai', 9848022330, 45000);
cqlsh:tutorialspoint> SELECT * FROM emp;
```

Mettre à jour

```
cqlsh:tutorialspoint> UPDATE emp
SET emp_city='Delhi',emp_sal=50000
WHERE emp_id=2;
cqlsh:tutorialspoint> SELECT * FROM emp;
```

Lire

```
cqlsh:tutorialspoint> SELECT emp_name, emp_sal from emp;
cqlsh:tutorialspoint> SELECT * FROM emp WHERE emp_sal=50000;
cqlsh:tutorialspoint> CREATE INDEX ON emp(emp_sal);
cqlsh:tutorialspoint> SELECT * FROM emp WHERE emp_sal=50000;
```

Supprimer

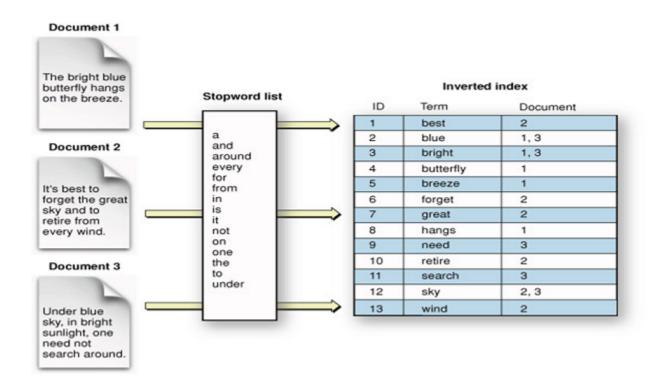
```
cqlsh:tutorialspoint> DELETE emp_sal FROM emp WHERE emp_id=3;
cqlsh:tutorialspoint> SELECT * FROM emp;
cqlsh:tutorialspoint> DELETE FROM emp WHERE emp_id=3;
cqlsh:tutorialspoint> SELECT * FROM emp;
```

Elasticsearch



- Indexation et recherche de données
- Moteur Lucene
- API HTTP RESTful en JSON

Elasticsearch



Elasticsearch Tutorial - Elasticsearch Storage Architecture : Analysis and Inverted Indexes

Elasticsearch

Tutorial

```
$ git clone https://github.com/fabienbarbaud/docker-elasticsearch.git
```

\$ cd docker-elasticsearch

\$ docker-compose up

http://localhost:5601

Elasticsearch Tutorial